

ECONOMETRIA II

Atividade I

Consumo mensal de eletricidade na China

Análise da série temporal de 2015 a 2024

Alex Tavares Cordeiro

Brenno Henrique Alves da Silva Costa

Professor: Cassio da Nobrega Besarria

15 de setembro de 2026

I Definição de série temporal

Uma série temporal é um conjunto de valores registrados ao longo do tempo, como o consumo de eletricidade em cada mês. A ordem dos registros importa, pois um valor pode estar relacionado aos meses anteriores e à mesma época de outros anos.

Este relatório usa os resultados do notebook `energia_china_estudo_completo.ipynb` para descrever a série, preencher valores faltantes, tratar valores muito diferentes do padrão e aplicar métodos de suavização.

II Série escolhida e estatística descritiva

A série escolhida é o **consumo mensal de eletricidade da China**, publicado pela *National Energy Administration* (NEA) [1, 2]. Os valores estão em TWh: 1 TWh equivale a um bilhão de kWh.

O período vai de janeiro de 2015 a dezembro de 2024, totalizando 120 meses. A base contém 99 valores publicados diretamente e nove janeiros calculados pela diferença entre o total de janeiro–fevereiro e fevereiro do mesmo boletim. Faltam 12 valores: os dez dezembros e janeiro e fevereiro de 2024. Esses meses não foram localizados separadamente na coleta; isso não significa consumo zero. O total do primeiro bimestre de 2024 está disponível [3]. Maio de 2023 veio de uma republicação no portal da NEA [4].

A periodicidade é **mensal**, com um padrão sazonal **anual**, de 12 meses. O gráfico mostra crescimento do consumo e valores geralmente mais altos em julho e agosto.




Figura 1: Consumo mensal de eletricidade na China, 2015–2024.

Fonte: Elaboração dos autores a partir dos resultados do notebook e dos dados da NEA.

A média foi de **617,93 TWh** por mês. A mediana, valor central dos dados ordenados, foi de 600,75 TWh. O desvio-padrão de 127,49 TWh mostra a dispersão em torno da média. Parte dessa variação vem do crescimento ao longo dos anos e das diferenças entre os meses. O mínimo foi de 359,50 TWh, em fevereiro de 2015, e o máximo, de 964,90 TWh, em agosto de 2024.

Tabela 1: Estatística descritiva antes do preenchimento das lacunas.

Medida	Resultado
Número de valores disponíveis	108
Média (TWh)	617,93
Mediana (TWh)	600,75
Desvio-padrão amostral (TWh)	127,49
Variância amostral (TWh ²)	16.254,46
Mínimo (TWh)	359,50
Primeiro quartil (TWh)	512,85
Terceiro quartil (TWh)	697,08
Máximo (TWh)	964,90
Amplitude (TWh)	605,40
Coefficiente de variação (%)	20,63
Assimetria	0,430
Excesso de curtose	-0,346

Fonte: Notebook, com os 108 valores disponíveis.

III Remoção de observações e imputação

Imputar significa estimar um valor que está faltando. Para avaliar os métodos, alguns valores conhecidos foram guardados e retirados da série. Depois, as estimativas foram comparadas com os valores guardados.

O experimento usou os dados de 2015 a 2022. Foram removidos, em quatro cenários, 10% dos 80 valores diretamente publicados, 20%, um bloco de três meses e um bloco de seis meses. Cada cenário foi repetido 20 vezes. Todos os métodos receberam as mesmas lacunas. Quando fevereiro era retirado, o janeiro calculado a partir dele também era escondido, para evitar que a resposta fosse recuperada indiretamente.

Foram comparados cinco métodos:

- **Média global:** usa a média dos valores que sobraram.
- **Interpolação linear:** liga os valores vizinhos por uma reta.
- **PCHIP:** liga os vizinhos por curvas que preservam a forma local dos dados.
- **Regressão harmônica no log:** ajusta uma tendência e ondas que representam o padrão anual. Usa o logaritmo dos valores e depois retorna à escala original.
- **Harmônica com resíduo:** acrescenta ao método anterior uma correção baseada nos desvios dos meses vizinhos.

A comparação usou o erro absoluto médio (MAE), o erro quadrático médio (EQM) e sua raiz (RMSE):

$$MAE = \frac{1}{n} \sum |y_t - \hat{y}_t|, \quad EQM = \frac{1}{n} \sum (y_t - \hat{y}_t)^2, \quad RMSE = \sqrt{EQM}.$$

Aqui, y_t é o valor guardado e $\hat{y}_t$, a estimativa. Quanto menor o erro, melhor o resultado. O EQM dá mais peso aos erros grandes.

Tabela 2: Erros médios dos métodos de imputação.

Método	MAE (TWh)	RMSE (TWh)	EQM (TWh ²)
Harmônica log	21,92	27,23	854,29
Harmônica + resíduo	28,50	35,27	1.376,09
Linear	42,88	51,55	3.272,50
PCHIP	44,41	53,13	3.541,18
Média global	91,83	104,15	12.207,00

Fonte: Experimentos do notebook.

Nota: Médias entre repetições e cenários, com peso igual por cenário. O EQM é calculado antes de tirar a média; por isso, não é o quadrado do RMSE médio.

A **regressão harmônica no log** foi a melhor pelo MAE, critério principal do notebook, e também pelo EQM. Ela foi usada para preencher as 12 lacunas originais, preservando os valores conhecidos. Como nenhum dezembro estava disponível, não foi possível conferir diretamente o erro das estimativas desse mês.

IV Identificação e tratamento de outliers

Outliers são valores muito diferentes do padrão esperado. Para encontrá-los, foi usada a STL robusta, que separa tendência, sazonalidade e resíduo, reduzindo a influência de valores extremos [5]. O resíduo é a parte que sobra após retirar os padrões estimados.

A detecção foi feita no logaritmo da série preenchida. Um ponto foi sinalizado quando seu resíduo ficou a mais de 3,5 escalas robustas da mediana. Essa escala é $1,4826 \times MAD$, em que MAD é a mediana das distâncias absolutas dos resíduos à sua mediana. Ela é menos afetada por extremos que o desvio-padrão. Apenas valores publicados diretamente foram avaliados como suspeitos.

Foram encontrados **seis pontos suspeitos**. Eles podem representar acontecimentos reais, e não erros. Por isso, o tratamento foi feito em uma cópia: aplicou-se a **winsorização**, que limita os resíduos extremos ao limite aceito e reconstrói o valor da série.

Tabela 3: Pontos suspeitos e valores após o tratamento na cópia de estudo.

Mês	Original (TWh)	z_t^*	Cópia tratada (TWh)
02/2017	448,80	6,00	435,61
02/2020	439,80	-14,63	502,25
03/2020	549,30	-8,48	582,95
07/2020	682,40	-4,79	692,94
02/2021	526,40	-7,24	550,39
02/2023	695,00	4,43	687,33

Fonte: Detecção por STL e tratamento por winsorização.

Nota: z_t^* indica a distância do resíduo à mediana em escalas robustas.

Também foram criados seis erros artificiais, multiplicando valores conhecidos por fatores entre 0,25 e 2,8. O detector encontrou os seis e sinalizou mais um ponto. Os suspeitos originais ficaram fora dessa avaliação, pois não se sabe se são erros.

Compararam-se três tratamentos: limitar os resíduos extremos; substituir os pontos pelo padrão estimado pela STL; e remover os pontos para preenchê-los pela regressão harmônica.

Tabela 4: Erros após tratar os outliers artificiais, em TWh.

Método	MAE nos 6	RMSE nos 6	MAE nos demais
Reconstrução STL	7,05	8,07	0,392
Remover e imputar	15,54	18,00	0,229
Winsorizar resíduos	30,02	31,80	0,009
Sem tratamento	676,21	758,27	0,000

Fonte: Comparação com os valores anteriores à alteração artificial.

Nota: As duas primeiras colunas de erro avaliam os seis pontos alterados; a última mostra o efeito nos demais pontos avaliados.

A **reconstrução STL** teve o menor MAE nos seis pontos: 7,05 TWh. Porém, alterou os demais pontos mais que a winsorização. Isso mostra que também é preciso observar o efeito do tratamento sobre valores que não eram erros.

V Média móvel, componentes e suavização

Os cálculos a seguir usam a cópia com lacunas preenchidas e suspeitos originais tratados. Os erros artificiais não entram nessa etapa.

V.1 Média móvel

A média móvel calcula a média de um grupo de meses próximos para reduzir oscilações. Foram usadas janelas de 3, 6 e 12 meses, incluindo o mês atual e os anteriores. Quanto maior a janela, mais suave e mais lenta é a resposta a mudanças.

$$MM_k(t) = \frac{y_t + y_{t-1} + \dots + y_{t-k+1}}{k}.$$

Em junho de 2024, as médias de 3, 6 e 12 meses foram, respectivamente, **778,93; 769,59; e 792,94 TWh**. Também foi calculada a média centrada 2×12 , que combina duas médias de 12 meses e usa valores antes e depois do mês analisado. Ela serve para estudar o passado, pois precisa de meses futuros.

V.2 Tendência, sazonalidade e ciclo

Tendência é o movimento de longo prazo. **Sazonalidade** é um padrão que se repete no calendário. **Ciclo** é uma oscilação mais lenta em torno da tendência, sem duração fixa. O **resíduo** é o que esses componentes não explicam.

A STL foi aplicada em TWh, com período 12, janela sazonal 13 e janela de tendência 25. O período 12 representa o ano. A janela 13 suaviza os registros do mesmo mês ao longo dos anos; não são 13 meses consecutivos. A janela 25 suaviza a tendência em cerca de dois anos. Essas são escolhas de suavização, não valores comprovadamente ideais.

Em seguida, o filtro Hodrick–Prescott (HP), com $\lambda = 129.600$, separou a parte suave da




Figura 2: Médias móveis: janelas maiores reduzem mais as oscilações.

Fonte: Elaboração dos autores a partir dos resultados do notebook e dos dados da NEA.

STL em tendência e ciclo [6]. O parâmetro λ controla quanto a tendência será suavizada. Assim:

$$y_t = \underbrace{T_t}_{\text{tendência}} + \underbrace{C_t}_{\text{ciclo}} + \underbrace{S_t}_{\text{sazonalidade}} + \underbrace{R_t}_{\text{resíduo}}.$$

Em agosto de 2024, por exemplo, $964,90 \approx 820,18 + 4,34 + 135,06 + 5,33$ TWh. A pequena diferença vem do arredondamento.




Figura 3: Componentes estimados da série.

Fonte: Elaboração dos autores a partir dos resultados do notebook e dos dados da NEA.

A tendência é crescente e a sazonalidade apresenta picos no meio do ano. O ciclo depende dos filtros escolhidos: ele não comprova, por si só, fases de crescimento ou recessão econômica.

V.3 Holt e Holt–Winters

Holt suaviza o nível e a tendência [7]. A cada mês, combina o valor novo com o que o modelo esperava. Sua previsão é o nível estimado mais a tendência multiplicada pelo número de meses à frente. Como não inclui sazonalidade, tem dificuldade para acompanhar os picos anuais.

Holt–Winters acrescenta o padrão sazonal de 12 meses [8]. Na versão **aditiva**, esse efeito é somado ao nível e à tendência. Na **multiplicativa**, ele é um fator proporcional: por exemplo, 1,10 representa 10% acima do nível previsto.

Os parâmetros α , β e γ controlam a atualização do nível, da tendência e da sazonalidade. Valores maiores fazem o modelo reagir mais às novas observações. Eles foram estimados buscando reduzir os erros de ajuste.

Tabela 5: Parâmetros estimados na série de estudo completa.

Modelo	α	β	γ
Holt	$1,49 \times 10^{-8}$	$1,49 \times 10^{-8}$	Não se aplica
Holt-Winters aditivo	0,145146	$5,19 \times 10^{-34}$	0,404602
Holt-Winters multiplicativo	0,186759	$9,38 \times 10^{-31}$	$1,19 \times 10^{-19}$

Fonte: Ajustes do notebook.

Os valores muito pequenos aparecem como zero quando arredondados. β próximo de zero indica que a inclinação muda pouco, não que a tendência desapareceu. No Holt, ela foi de aproximadamente **3,318 TWh por mês**. No Holt–Winters multiplicativo, γ próximo de zero indica pouca atualização do padrão sazonal inicial.

Em agosto de 2024, os valores ajustados foram 810,49 TWh para Holt, 921,17 TWh para Holt–Winters aditivo e 937,34 TWh para o multiplicativo, diante de 964,90 TWh observados. Esses ajustes usam a amostra completa.

Para comparar previsões, os modelos foram ajustados até 2022 e avaliados em 2023. O **Holt–Winters aditivo** foi escolhido pelo menor MAE: 25,09 TWh. Depois, ajustado até 2023, teve MAE de 18,84 TWh em 2024. O multiplicativo teve erro menor em 2024, de 16,45 TWh, mas a escolha anterior foi mantida para não usar o teste na seleção. O preenchimento e o tratamento foram refeitos somente com os dados de cada treino. A avaliação abrange dez meses diretamente publicados de 2023 e nove de 2024.




Figura 4: Série de estudo e valores ajustados por Holt e Holt–Winters.

Fonte: Elaboração dos autores a partir dos resultados do notebook e dos dados da NEA.

Conclusão

A série mostrou crescimento do consumo e um padrão anual. A regressão harmônica foi a melhor para preencher as lacunas avaliadas, e a reconstrução STL teve o menor erro no tratamento dos outliers artificiais. As médias móveis e a decomposição facilitaram a leitura dos padrões, enquanto Holt–Winters acompanhou melhor a sazonalidade. Os resultados dependem das estimativas para os meses faltantes, especialmente dezembro.

Referências

- [1] NATIONAL ENERGY ADMINISTRATION. *Arquivo de publicações da área de planejamento*. [Acessar fonte](#).
- [2] NATIONAL ENERGY ADMINISTRATION. *Consumo de eletricidade em março de 2024*. 17 abr. 2024. [Acessar fonte](#).
- [3] NATIONAL ENERGY ADMINISTRATION. *Consumo de eletricidade em janeiro–fevereiro de 2024*. 20 mar. 2024. [Acessar fonte](#).
- [4] NATIONAL ENERGY ADMINISTRATION. *Consumo de eletricidade em maio de 2023*. Republicação de notícia do People’s Daily no portal de cooperação energética, 16 jun. 2023. [Acessar fonte](#).
- [5] STATSMODELS. *STL: Season-Trend decomposition using LOESS*. Documentação. [Acessar fonte](#).
- [6] STATSMODELS. *Hodrick–Prescott filter*. Documentação. [Acessar fonte](#).
- [7] STATSMODELS. *Holt’s Exponential Smoothing*. Documentação. [Acessar fonte](#).
- [8] STATSMODELS. *ExponentialSmoothing: Holt–Winters*. Documentação. [Acessar fonte](#).